

Soluciones comentarios


Ayala Flores Luis Gerardo

En este documento solamente se hará mención de los resultados importantes, si se quiere ver de forma más técnica como se llegaron a los resultados se pueden ver a detalle en el script.

Ejercicio 1


En el trabajo se observaron unos datos dados, primero se calculó $\hat{\mu} = 2.4408852$ después se graficó el histograma, junto con la función de densidad de los datos, la idea de proponer una distribución $\mathcal{N}(\hat{\mu}, \sigma(\text{datos}))$ fue natural e intuitiva, al ver que esta quedaba por debajo del histograma, se propuso $\mathcal{N}(\hat{\mu}, 1)$ para aumentar la altura de la gráfica pasada, pero esta sobrepasó al histograma, así que se propuso la distribución $\mathcal{N}(\hat{\mu}, 1.088665)$ donde 1.088665 es el promedio de las desviaciones de las distribuciones anteriores, y efectivamente esta distribución queda en medio, se puso también la $\mathcal{N}(0, 1)$ para referencia, lo anteriormente dicho se puede observar en el siguiente gráfico

```
graficas_densidades()
```



Donde el parecido en las distribuciones se ven más es en las gráficas de las distribuciones como se verá a continuación.

```
graficas_distribuciones()
```



Ya que se parecen mucho vamos a hacer la prueba de Anderson-Darling, con un nivel de significancia $\alpha = 0.05$ teniendo los siguientes resultados de los p-values


```
prueba()
```

```
## $Normal_Sdmuestra
## [1] 0.08569876
##
## $Normal_1
## [1] 0.06271332
##
## $Normal_1.088
## [1] 0.09201622
```

Vemos que ninguna distribución rechazamos pero la que tiene mayor p-values es la distribución $\mathcal{N}(\hat{\mu}, 1.088665)$. Veamos cómo se ven los gráficos las distribución elegida


```
hist(muestra, freq = F, col = mis.colores(14), xlab = "Muestra observada")
curve(dnorm(x, mu_hat, sum(sd(muestra), 1)/2), col = "Red", add = T, lwd = 3)
lines(density(muestra), lwd = 3, col = "blue")
legend(max(muestra) - 3.5, 0.35,
c("Distribucion de la muestra", "Distribucion elegida"), col = c("Blue", "Red"), lty = 1, lwd = 2)
```

Histogram of muestra



Ahora la gráfica de la distribución

```
curve(f_gorro(x),col="Blue",-5,5,lwd=3)
curve(pnorm(x,mu_hat,sum(sd(muestra),1)/2),col="Red",add = T,lwd = 3)
legend(min(muestra)-6,1,
c("Distribucion de la muestra","Distribucion elegida"),col =c("Blue","Red"),lty=1,lwd=2)
```




Ejercicio 2

Para este ejercicio se programaron las funciones para hacer las funciones correspondientes para hacer los remuestreos. A continuación, se pondrá los resultados obtenidos por cada método

Bootstrap paramétrico

```
Bootparametrico(muestra)
```



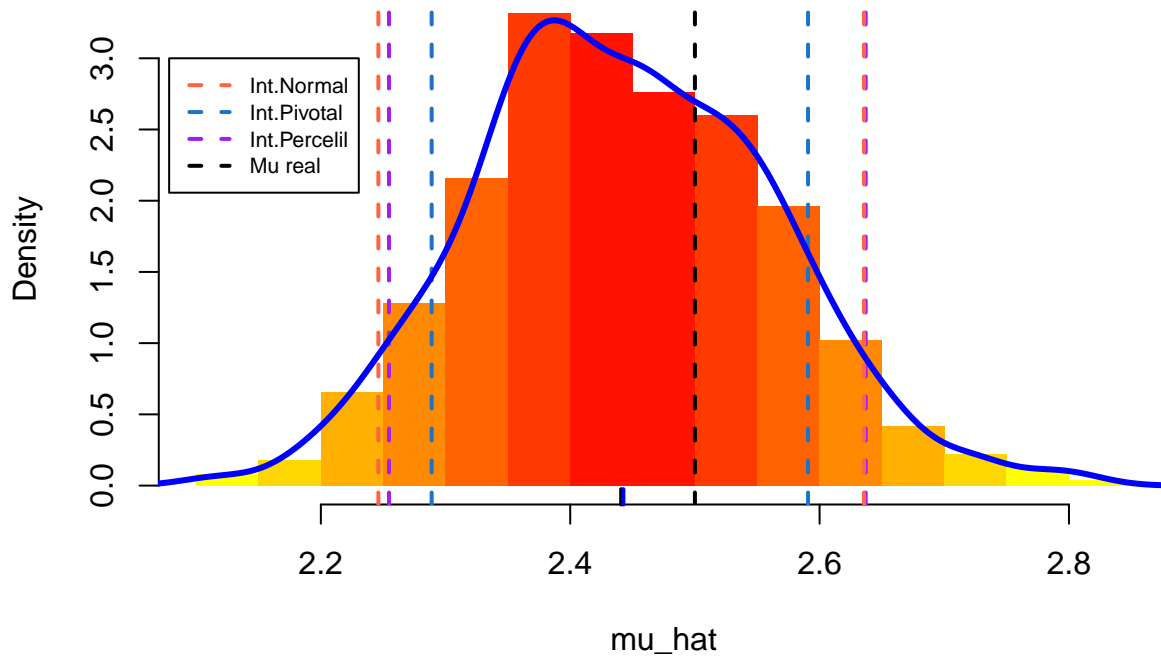
```
## $Estadistico
## [1] 2.440885
##
## $Estimacion
## [1] 2.443189
##
## $Sd_hat_bp
## [1] 0.1107237
##
## $min_max
## [1] 2.070793 2.765046
##
## $Int.Normal
## [1] 2.258761 2.623010
##
## $Amplitud.Normal
## [1] 0.3642486
```

La línea inferior azul es la estimación del remuestreo y la línea negra inferior es $\hat{\mu}$. Veamos que la línea negra es la distribución propuesta.

Bootstrap no paramétrico

Bootnparametrico(muestra)

Bootstrap No Parametrico



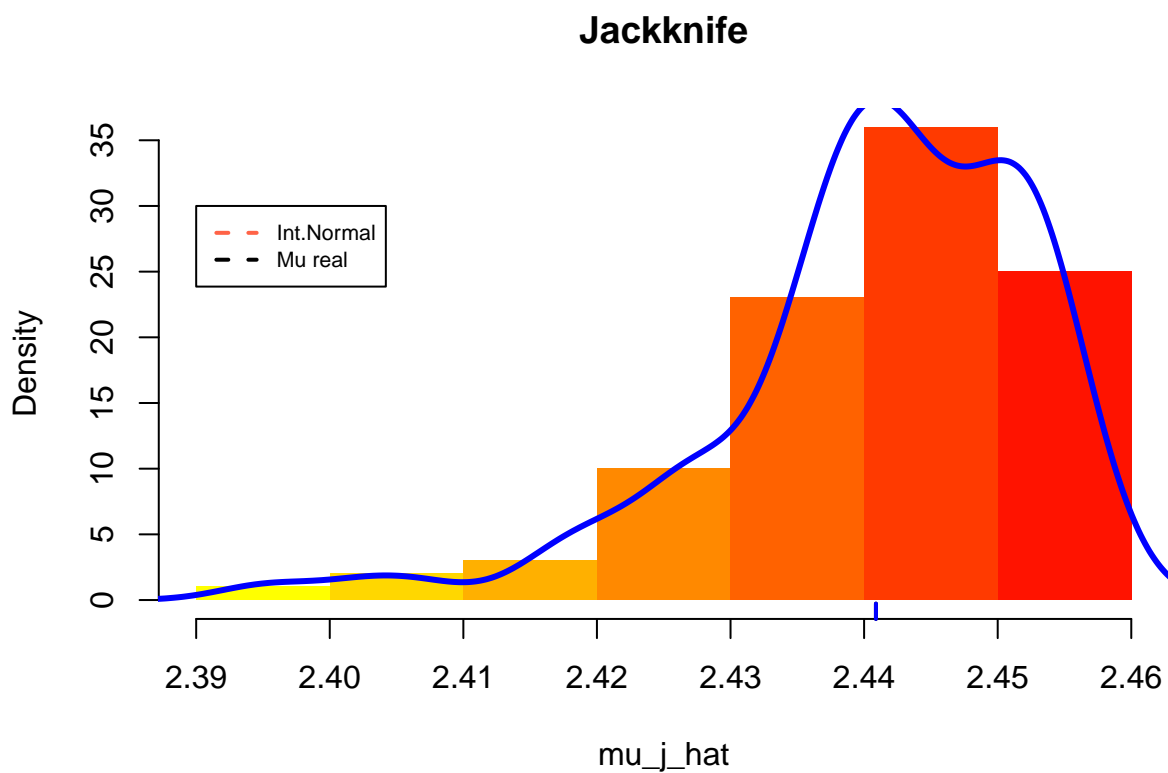
```
## $Estadistico
## [1] 2.440885
##
## $Estimacion
## [1] 2.442637
##
## $Sd_hat_bnp
## [1] 0.1184
##
## $min_max
## [1] 2.103323 2.814467
##
## $Int.Normal
## [1] 2.246135 2.635636
##
## $Amplitud.Normal
## [1] 0.3895013
##
## $Int.Pivotal
##      90%      10%
## 2.288856 2.590758
##
## $Amplitud.Pivotal
##      10%
## 0.3019016
```

```
##
## $Int.Percentil
##      5%      95%
## 2.254650 2.636976
##
## $Amplitud.Percentil
##      95%
## 0.3481202
```

La línea inferior azul es la estimación del remuestreo y la línea negra inferior es $\hat{\mu}$.

Jackknife

```
Jackknife(muestra)
```



```
## $Estadistico
## [1] 2.440885
##
## $Estimacion
## [1] 2.440885
##
## $Sd_hat_jackk
## [1] 0.1177329
##
## $min_max
## [1] 2.395236 2.458216
##
## $Int.Normal
## [1] 2.247232 2.634539
```

```
##
## $Amplitud.Normal
## [1] 0.3873069
```

A diferencia de los otros el histograma queda diferente ya que se siguen teniendo pocas muestras a comparación con los Bootstrap, es mas en el histograma no se alcanza a ver el valor real de μ veamos si esto afecta en algo a en los intervalos del ejercicio 3.

Ejercicio 3

A continuación podremos los intervalos para ver la hipótesis

$$H_0 : \mu = 2.5 \quad \text{vs} \quad H_1 : \mu \neq 2.5$$

Intervalo Normal

En los siguientes intervalos se toma 90% de confianza

Bootstrap paramétrico

```
Parametrico$Int.Normal
## [1] 2.258761 2.623010
Parametrico$Amplitud.Normal
## [1] 0.3642486
```

Podemos ver qué μ_o cae dentro del intervalo, esto también lo vemos gráficamente, así que no rechazamos H_0 , además vemos que la longitud del intervalo es de 0.3642486

Bootstrap no paramétrico

```
BNoparametrico$Int.Normal
## [1] 2.246135 2.635636
BNoparametrico$Amplitud.Normal
## [1] 0.3895013
```

Podemos ver qué μ_o cae dentro del intervalo, esto se logra ver en el gráfico, así que no rechazamos H_0 , además la longitud del intervalo es de 0.3895

Jackknife

```
Jackk$Int.Normal
## [1] 2.247232 2.634539
Jackk$Amplitud.Normal
## [1] 0.3873069
```

Vemos que a pesar que en el histograma no veíamos al valor real de μ y los intervalos como en los otros gráficos, μ_o cae dentro del intervalo así que no rechazamos H_0 y la longitud del intervalo es de 0.3873069. Vemos que el que tiene mayor longitud de intervalo es el de Bootstrap no paramétrico.

Intervalo Pivotal

```
BNoparametrico$Int.Pivotal
```

```
##          90%          10%
## 2.288856 2.590758
```

```
BNoparametrico$Amplitud.Pivotal
```

```
##          10%
## 0.3019016
```

Podemos ver que μ_o cae dentro del intervalo, esto también se observa gráficamente, así que no rechazamos H_0 , además la longitud del intervalo es de 0.3019016

Intervalo Percentil

```
BNoparametrico$Int.Percentil
```

```
##          5%          95%
## 2.254650 2.636976
```

```
BNoparametrico$Amplitud.Percentil
```

```
##          95%
## 0.3481202
```

Podemos ver que μ_o cae dentro del intervalo, esto se puede ver gráficamente, así que no rechazamos H_0

Podemos ver que para Bootstrap el intervalo pivotal es el más pequeño y además no se rechaza la hipótesis, así que preferimos este intervalo. También podemos concluir que Bootstrap paramétrico fue la que estimó la menor desviación estándar (0.1107237)